Análise de dados e implantação de modelos de machine learning em aplicações web.





UNIVERSIDADE FEDERAL DO ESTADO DO RIO DE JANEIRO

Introdução: apresentação

Henrique S. Rodrigues:



- **Técnico em Informática** pelo CEFET, tendo se formado em 2017.
- **Bacharel em Sistemas de Informação** pela UNIRIO, tendo se formado em 2022.
- **Mestre em Informática** pela UNIRIO tendo se titulado em 2025.
- **Doutorando em Informática** pela UNIRIO.
- E-mail: henrique.rodrigues@edu.unirio.br

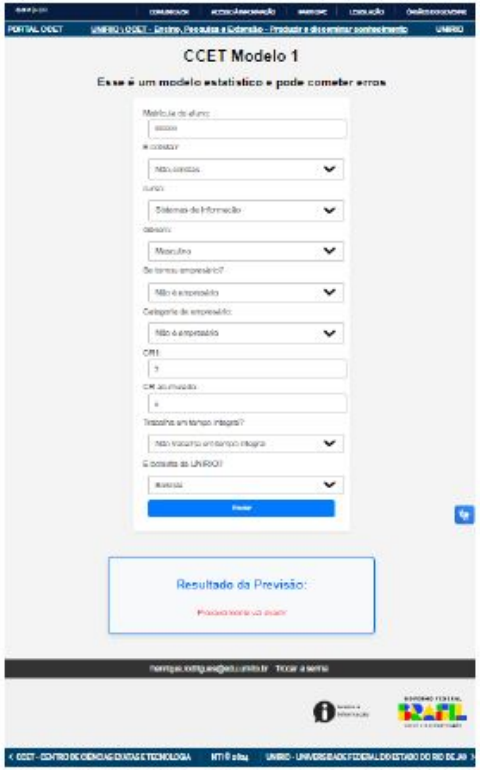
Introdução: pesquisa

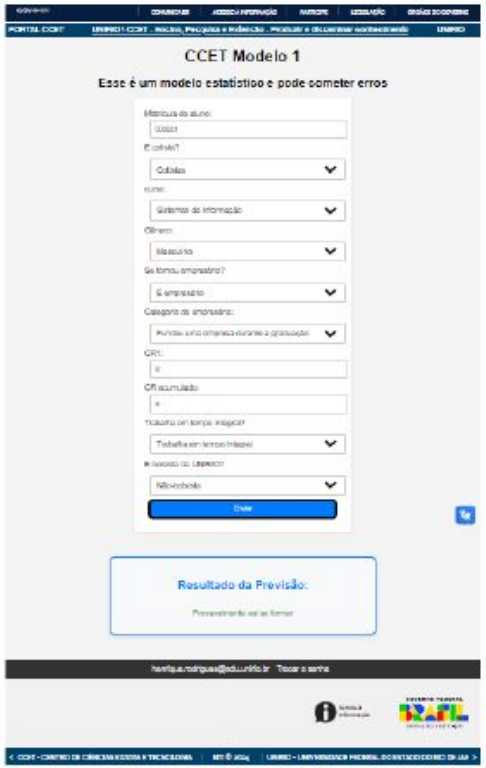
- A pesquisa consiste em **analisar fatores e características da evasão de alunos** do CCET da UNIRIO.
- Como resultados, estamos vendo que alunos que passam **dificuldades em matemática e programação básica nos primeiros períodos** tendem a evadir mais.
- **Não foi encontrado correlação entre trabalho em tempo integral e empreendedorismo com evasão.**
- Foi encontrada uma **correlação negativa entre recebimento de bolsa e evasão.**



Introdução: pesquisa

- Depois das análises estatísticas foi criado o Sistema Preditor de Evasão, que se utiliza do algoritmo de IA Gradient Boosting para identificar alunos em risco de evasão.

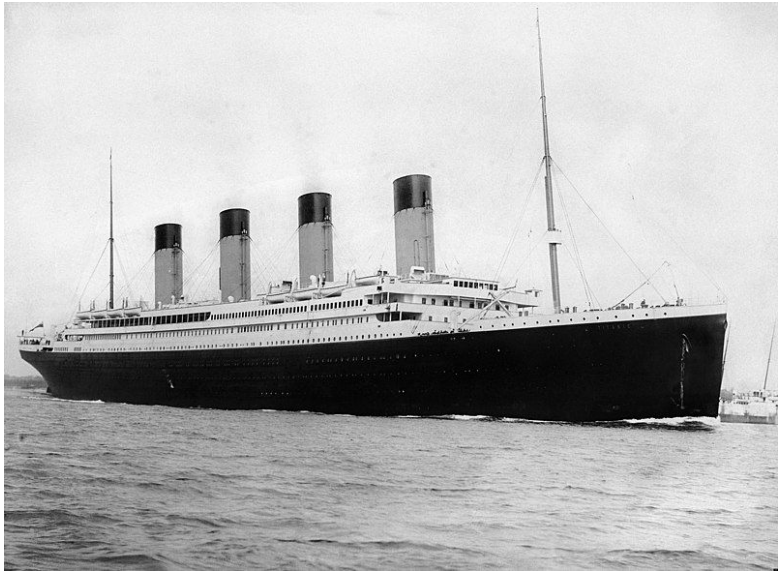




Objetivo do Minicurso

- O objetivo desse minicurso é oferecer uma **introdução prática a Ciência de Dados e Inteligência Artificial.**

- Para atingir esse objetivo, vamos visitar um **miniprojeto com dados dos passageiros do Titanic.**



Fases do Miniprojeto

O miniprojeto é divido em três fases:

Na primeira fase, iremos fazer uma **análise exploratória estatística** utilizando Python no Google Colab.

Na segunda fase, iremos **treinar o algoritmo** Gradient Boosting para identificar algum **padrão interessante.**

Na terceira fase, iremos exportar o algoritmo treinado para um **sistema web**, utilizando Python Flask no back-end, e Vue.JS no front-end.

Fontes de Dados Abertos

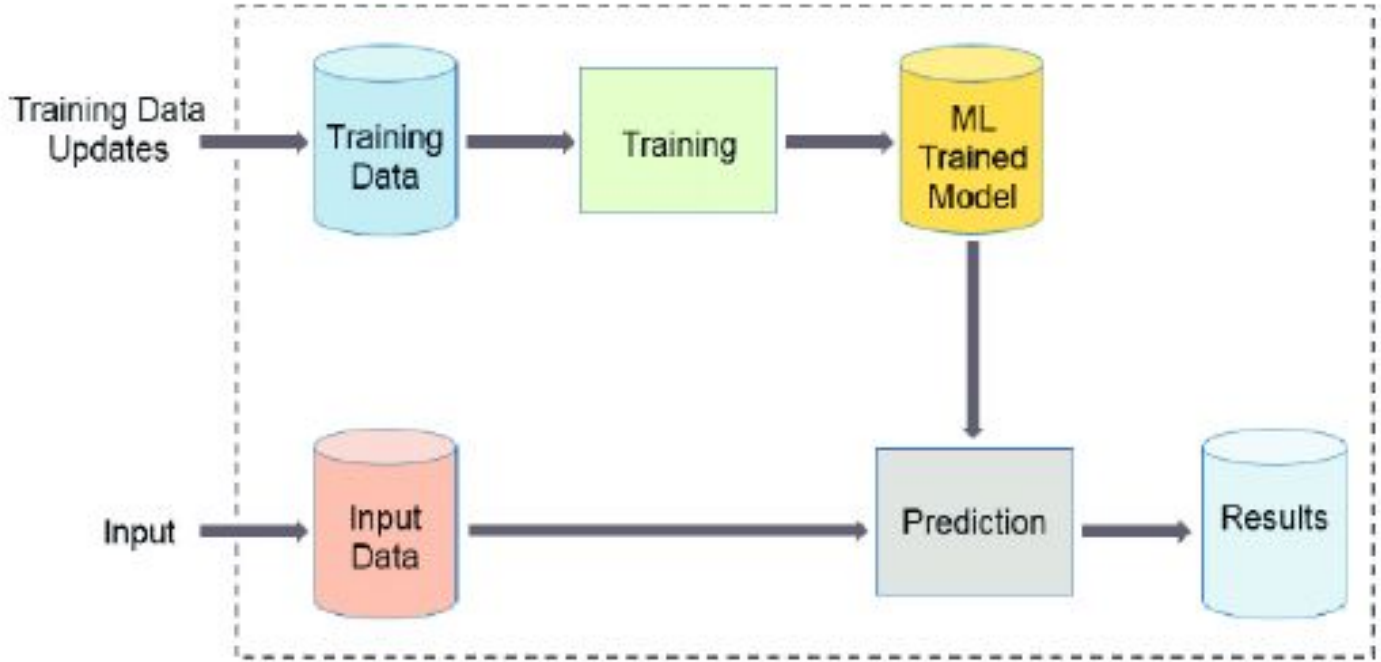
Espera-se que ao fim do minicurso, o cursista seja **capaz de fazer análises e treinar uma IA** com outras fontes de dados. E quem sabe, **escrever seu próprio artigo científico?**

Base dos Dados: https://basedosdados.org/

Kaggle: https://www.kaggle.com/

UC Irvine Machine Learning Repository: https://archive.ics.uci.edu/

Workflow de uma Aplicação com Machine Learning



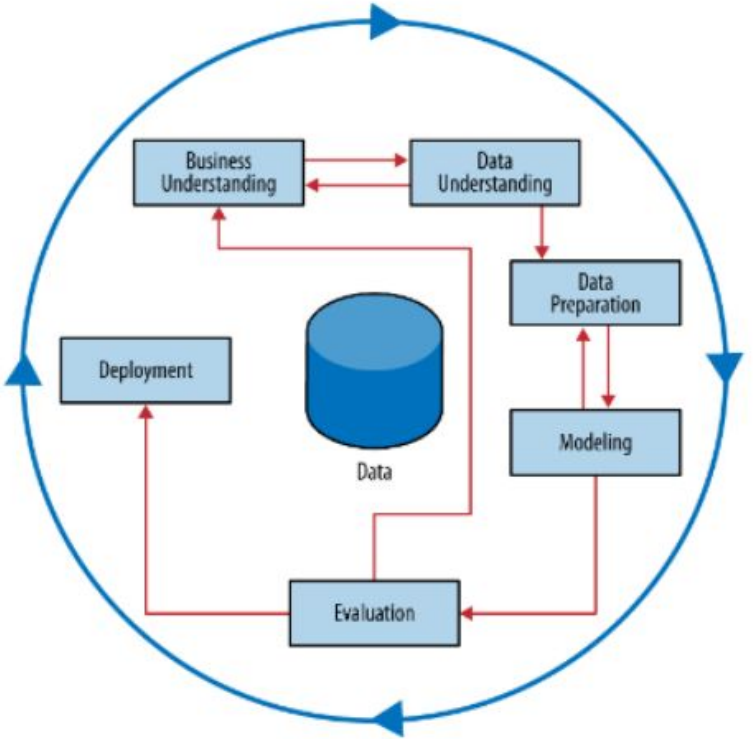
Workflow de uma Aplicação com Machine Learning

Nome	Gênero	Idade	Tarifa	Porto de Origem	Sobreviveu?
Passageiro Real 1	Masculino	26	300 libras esterlinas	Cherbourg	Sim
Passageira Real 2	Feminino	24	100 libras esterlinas	Queenstown	Não
Passageiro Hipotético 1	Masculino	19	200 libras esterlinas	Southampton	??? (É o que queremos prever)

Método: Cross Industry Standard Process for Data Mining (CRISP-DM)

Etapas:

1. Entendimento do problema
2. Entendimento dos dados
3. Preparação do dados
4. Modelagem
5. Avaliação do modelo
6. Implementação do modelo



Entendimento do Problema

- O Titanic foi um navio de passageiros que a**fundou em sua primeira viagem em 1912.**

- Na época, a comunicação era mais lenta e difícil, portanto, os parentes amigos dos passageiros **poderiam ter dificuldades em pensar em uma probabilidade de sobrevivência de seus ente-queridos.**

- Se houvesse um acidente parecido hoje em dia, com a nossa tecnologia atual, **será que poderíamos identificar quais passageiros poderiam ter sobrevivido ou não?**



Entendimento do dados

Os dados estão disponíveis em https://www.kaggle.com/competitions/titanic/data

Qual desses dados queremos prever com IA?

Variable	Definition	Key
survival	Survival	0 = No, 1 = Yes
pclass	Ticket class	1 = 1st, 2 = 2nd, 3 = 3rd
sex	Sex	
Age	Age in years	
sibsp	# of siblings / spouses aboard the Titanic	
parch	# of parents / children aboard the Titanic	
ticket	Ticket number	
fare	Passenger fare	
cabin	Cabin number	
embarked	Port of Embarkation	C = Cherbourg, Q = Queenstown, S = Southampton

Preparação dos dados

Às vezes, **nem sempre os dados já estão “bonitinhos”** para serem usados prontamente.
Pode ser necessário, a depender da situação:

- Apagar linhas com dados faltantes ou preencher os dados faltantes com uma média para não atrapalhar as análises.

- Apagar outliers, que são dados muito destoantes da mediana dos dados.

- Fazer recortes, como um recorte temporal ou região geográfica, a depender do escopo do projeto.

Nesse caso, apenas removeremos os outliers para fazer uma das análises.

Preparação dos dados

- Pode ser necessário fazer resampling (reamostragem) de dados caso haja classes desbalanceadas.
- Por exemplo, ter muito mais falecidos do que sobreviventes.
- Nesses casos, um algoritmo popular de resampling é o SMOTE.
- Caso as classes sejam muito desbalanceadas, pode haver viés no modelo.

Modelagem: Análise Exploratória

Por favor, **COPIEM** o seguinte notebook Python:

https://colab.research.google.com/drive/1bByShLdYOe-mC9LvTQ9VQU58RaFBuugl?usp=sharing

Gráficos mais comuns que podem ser feitos:

- Gráfico de Pizza
- Gráfico de Barras
- Boxplot
- Histograma

Recomendo usar a biblioteca Plotly para fazer os gráficos

Modelagem: Análise Exploratória

Por favor, **COPIEM** o seguinte notebook Python:

https://colab.research.google.com/drive/1bByShLdYOe-mC9LvTQ9VQU58RaFBuugl?usp=sharing

O Teste de Qui-Quadrado, ou Chi Square, é um teste estatístico cujo objetivo é verificar se duas variáveis são independentes entre si ou se há alguma correlação entre elas. As hipóteses são:

H0: as duas variáveis analisadas são independentes.

H1: as duas variáveis são dependentes uma da outra.

Caso o p-valor do teste dê menos do que 0,05, rejeitamos a H0.

Modelagem: Análise Exploratória

Por favor, **COPIEM** o seguinte notebook Python:

https://colab.research.google.com/drive/1bByShLdYOe-mC9LvTQ9VQU58RaFBuugl?usp=sharing

Quais outros gráficos podemos fazer?

Após a fase de Análise Exploratória, quais conclusões podemos tirar?

Vamos debater!

Modelagem: Treinamento de um Modelo de Machine Learning

Por favor, **COPIEM** o seguinte notebook Python:

https://colab.research.google.com/drive/1bByShLdYOe-mC9LvTQ9VQU58RaFBuugl?usp=sharing

Os principais algoritmos de Machine Learning são:

- Decision Tree
- Random Forest
- Gradient Boosting
- Support Vector Machine
- Logistic Regression

Cada modelo pode possuir hiperparâmetros para se configurar.

Modelagem: Treinamento de um Modelo de Machine Learning

Por favor, **COPIEM** o seguinte notebook Python:

https://colab.research.google.com/drive/1bByShLdYOe-mC9LvTQ9VQU58RaFBuugl?usp=sharing

É necessário converter as variáveis categóricas em variáveis numéricas, podemos fazer isso de dois jeitos:

- Fazendo manualmente um mapa entre categorias e números.
- Usando o LebelEnconder. Baixaremos os arquivos .pkl gerados por ele para usarmos mais tarde.

Não faz sentido usar nomes e IDs nos modelos!

Avaliação do Modelo

Por favor, **COPIEM** o seguinte notebook Python:

https://colab.research.google.com/drive/1bByShLdYOe-mC9LvTQ9VQU58RaFBuugl?usp=sharing

	Actual Positive	Actual Negative
Predicted Positive	True Positives (TP)	False Positives (FP)
Predicted Negative	False Negatives (FN)	True Negatives (TN)

$$\text{Accuracy} = \frac{\text{Number of Correct Predictions}}{\text{Total Number of Predictions}} = \frac{TP + TN}{TP + TN + FP + FN}$$

Avaliação do Modelo

Por favor, **COPIEM** o seguinte notebook Python:

https://colab.research.google.com/drive/1bByShLdYOe-mC9LvTQ9VQU58RaFBuugl?usp=sharing

	Actual Positive	Actual Negative
Predicted Positive	True Positives (TP)	False Positives (FP)
Predicted Negative	False Negatives (FN)	True Negatives (TN)

$$\text{Precision (TP)} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

$$\text{Precision (TN)} = \frac{\text{True Negatives}}{\text{True Negatives} + \text{False Negatives}} = \frac{\text{TN}}{\text{TN} + \text{FN}}$$

Avaliação do Modelo

Por favor, **COPIEM** o seguinte notebook Python:

https://colab.research.google.com/drive/1bByShLdYOe-mC9LvTQ9VQU58RaFBuugl?usp=sharing

	Actual Positive	Actual Negative
Predicted Positive	True Positives (TP)	False Positives (FP)
Predicted Negative	False Negatives (FN)	True Negatives (TN)

$$\text{Recall (TP)} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

$$\text{Recall (TN)} = \frac{\text{True Negatives}}{\text{True Negatives} + \text{False Positives}} = \frac{\text{TN}}{\text{TN} + \text{FP}}$$

Avaliação do Modelo

Por favor, **COPIEM** o seguinte notebook Python:

https://colab.research.google.com/drive/1bByShLdYOe-mC9LvTQ9VQU58RaFBuugl?usp=sharing

	Actual Positive	Actual Negative
Predicted Positive	True Positives (TP)	False Positives (FP)
Predicted Negative	False Negatives (FN)	True Negatives (TN)

$$\text{F1 score} = \frac{2 \times (\text{Precision} \times \text{Recall})}{\text{Precision} + \text{Recall}}$$

Avaliação do Modelo

Por favor, **COPIEM** o seguinte notebook Python:

https://colab.research.google.com/drive/1bByShLdYOe-mC9LvTQ9VQU58RaFBuugl?usp=sharing

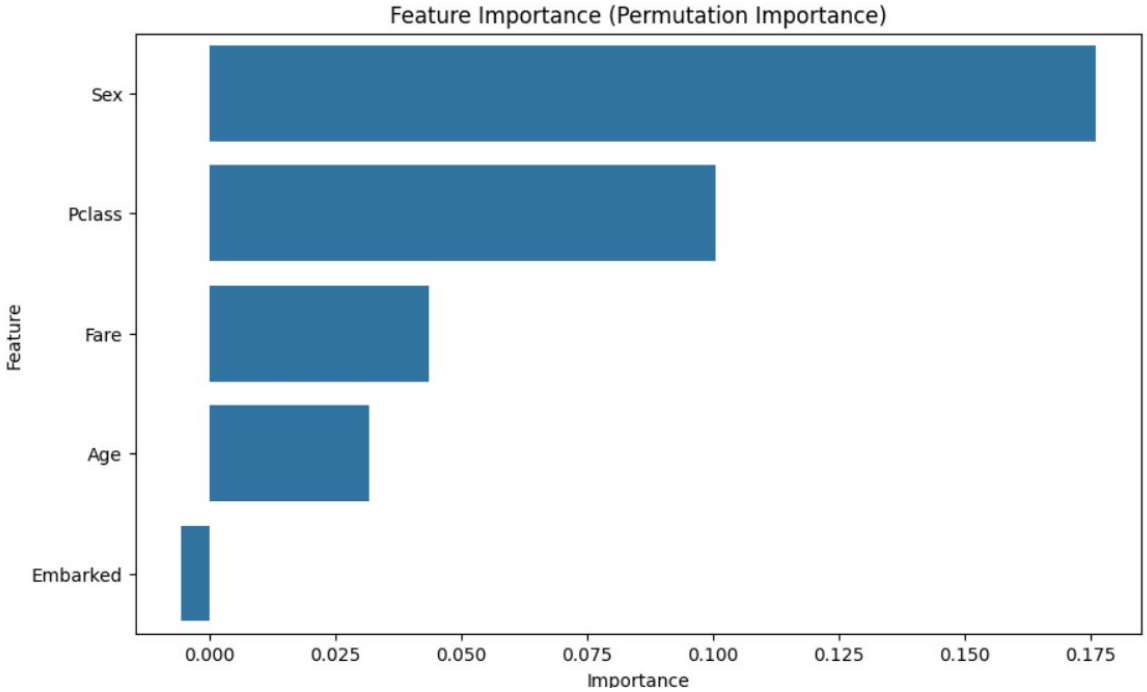
Vocês consideram que as métricas do nosso modelo foram boas? Será que poderíamos alcançar um resultado melhor com outro algoritmo?

```
Model accuracy: 0.8156424581005587
Report:
              precision    recall  f1-score   support

           0       0.83      0.86      0.85       105
           1       0.79      0.76      0.77        74
```

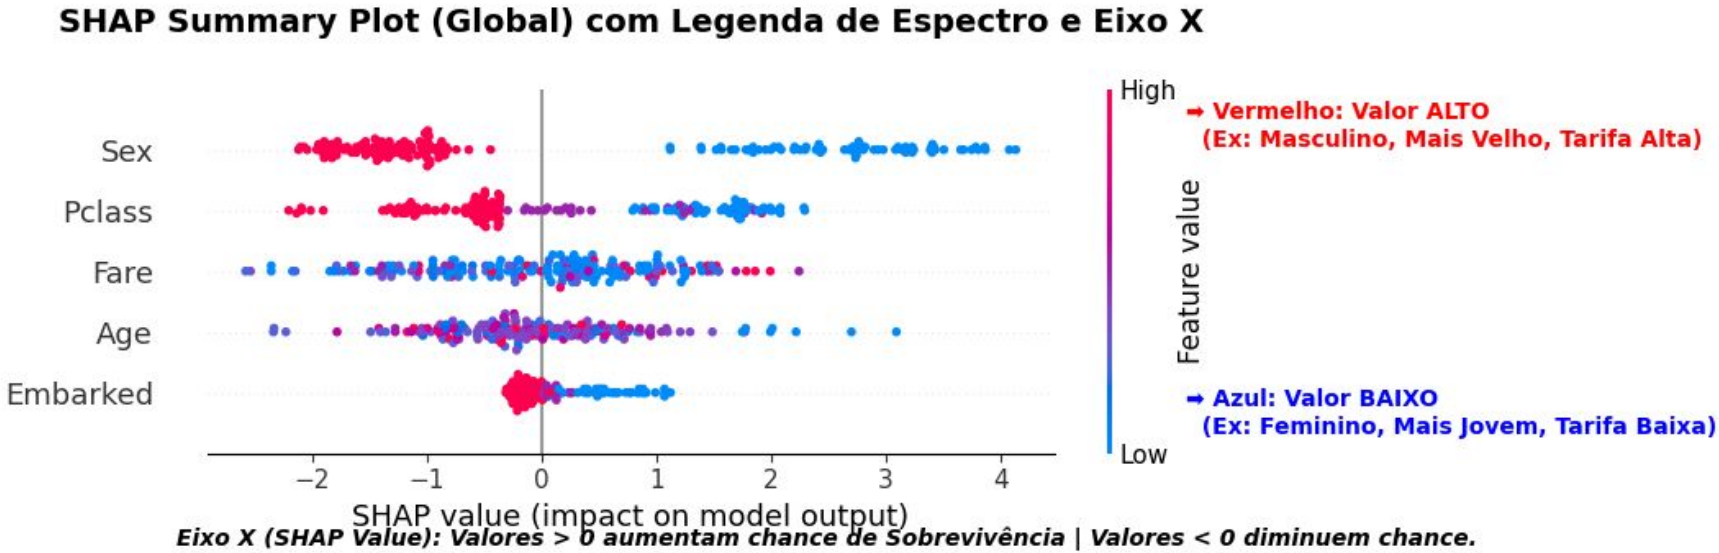
Importância das variáveis pelo modelo

As variáveis mais importantes para o modelo são coerentes com a nossa análise feita anteriormente?



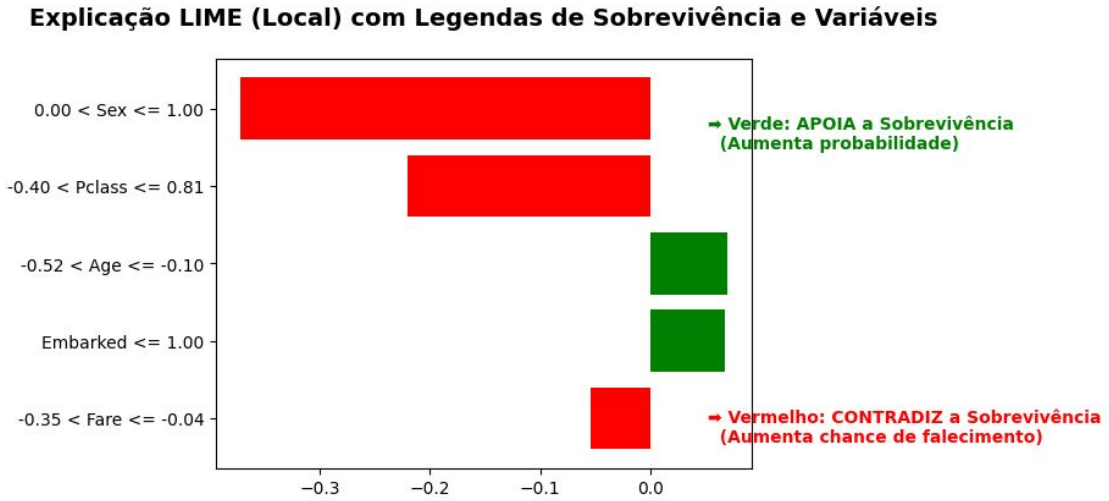
SHAP

As variáveis mais importantes para o modelo são coerentes com a nossa análise feita anteriormente?



Lime

As variáveis mais importantes para o modelo são coerentes com a nossa análise feita anteriormente?



Eixo X (Weight): Magnitude do impacto local na probabilidade de sobrevivência.

Significado das escalas das variáveis (Eixo Y):
- ***Sex: 0 = Feminino | 1 = Masculino***
- ***Pclass: 1 = Classe Alta (Luxo) | 2 = Média | 3 = Classe Baixa***
- ***Embarked: 0 = Cherbourg (C) | 1 = Queenstown (Q) | 2 = Southampton (S)***
- ***Fare e Age: Valores numéricos de tarifa paga e idade (padronizados).***

Implementação do Modelo

Agora que temos um modelo pronto, o que podemos fazer com ele?

Podemos exportá-lo para uma aplicação web para fazer uma predição com novos dados!

Baixe os arquivos dos encoders das variáveis categóricas:

```
le = LabelEncoder()

# Transformando e salvando os encoders
data_modelo['Sex'] = le.fit_transform(data_modelo['Sex'])
joblib.dump(le, 'label_encoder_Sex.pkl')
files.download(f'label_encoder_Sex.pkl')


data_modelo['Embarked'] = le.fit_transform(data_modelo['Embarked'])
joblib.dump(le, 'label_encoder_Embarked.pkl')
files.download(f'label_encoder_Embarked.pkl')
```

Implementação do Modelo

Baixe o do modelo exportado:

```
X = data_modelo[numerical_columns + categorical_columns]
y = data_modelo['Survived']

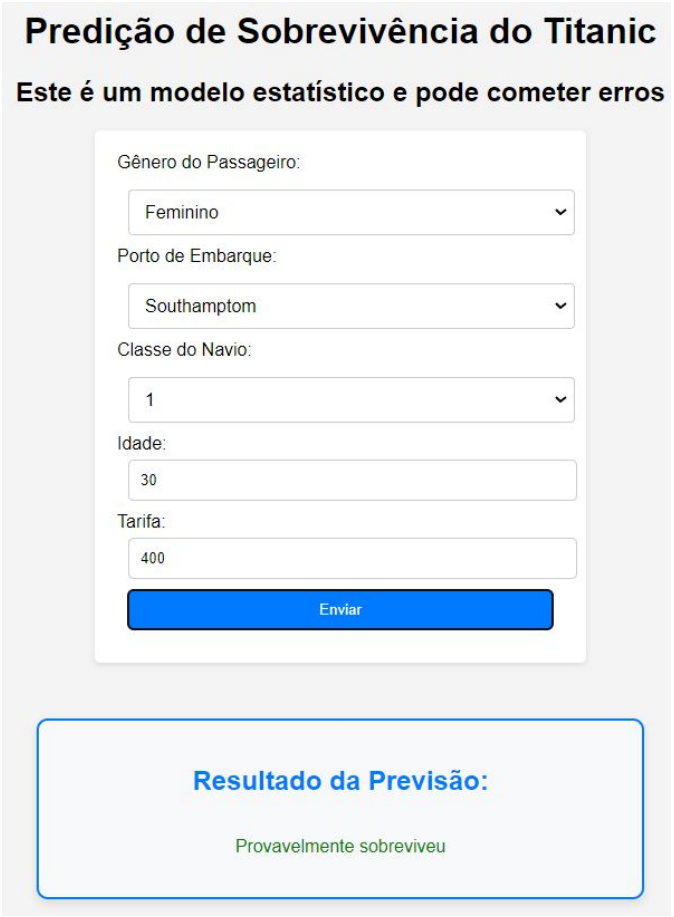
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

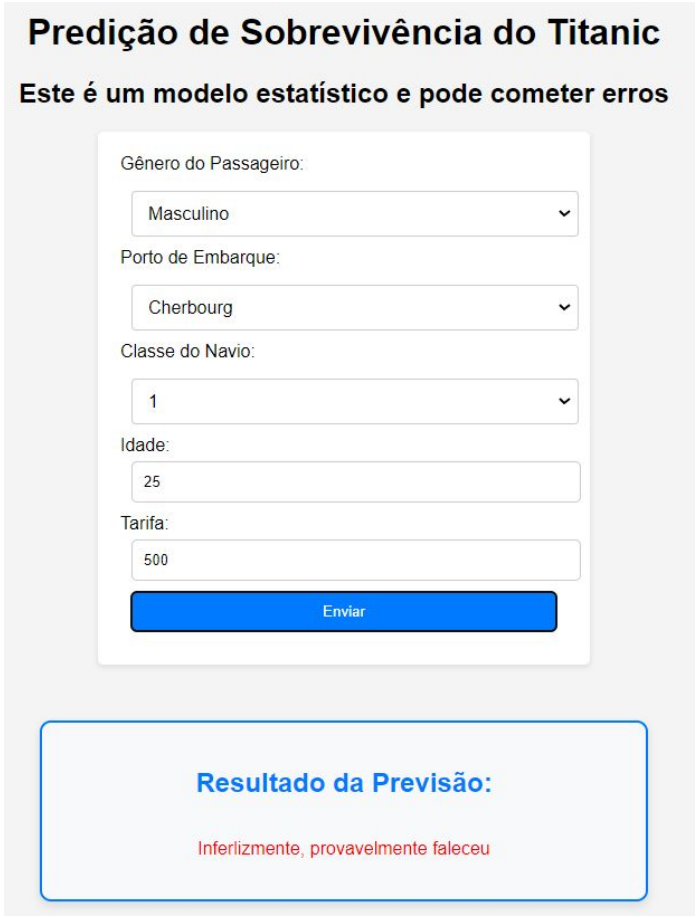
pipeline.fit(X_train , y_train)

# Salvar o pipeline inteiro
joblib.dump(pipeline, 'modelo_titanic.pkl')
files.download('modelo_titanic.pkl')
```

Baixem o código em:
https://github.com/HenriqueSoaresRodrigues/TitanicSurvivePrediction

Implementação do Modelo





Dúvidas?
Questões?
Discussões?





UNIVERSIDADE FEDERAL DO ESTADO DO RIO DE JANEIRO